

关于自动求导机制的理解

Yzy

2019 年 8 月 30 日

目录

1 投影值, 投影向量	1
2 方向导数与梯度的关系	1
3 auto grad 理解	2

1 投影值, 投影向量

由向量点乘公式以及直角三角形来推投影值 $\text{Prj}_{\mathbf{a}} \mathbf{b} = \mathbf{b} \cdot \frac{\mathbf{a}}{|\mathbf{a}|}$ 。

$$\vec{a} \cdot \vec{b} = |\vec{a}| |\vec{b}| \cos \theta \rightarrow \cos \theta = \frac{\vec{a} \cdot \vec{b}}{|\vec{a}| |\vec{b}|}$$

由直角三角形三边之间的关系可知, 直角边 = 斜边乘上 $\cos \theta$ 。即直角边长 $= \vec{b} \cos \theta = \frac{\vec{a} \cdot \vec{b}}{|\vec{a}|}$, 也就是 \mathbf{b} 在 \mathbf{a} 上的投影值 (投影向量的模)!

而 \mathbf{b} 在 \mathbf{a} 上的投影向量 $\vec{p} = x\vec{a}$, 其中 x 是倍数! 倘若 $\vec{p} = x \frac{\vec{a}}{|\vec{a}|}$ 则 x 便是上述的投影值!

2 方向导数与梯度的关系

$\frac{\partial f}{\partial l} = \text{grad } f \cdot \frac{\vec{l}}{|\vec{l}|}$, 可以看出: 方向导数是梯度在向量 \vec{l} 上的投影!

所以当沿 \vec{l} 方向的单位向量 $\vec{v} = \frac{\vec{l}}{|\vec{l}|} = (1, 1, 1)$ 时, 方向导数便是梯度!!!

3 auto grad 理解

以三维向量为例: $X = [x_1, x_2, x_3] \rightarrow Y = X^2$

Y 对 X 的导数即为向量对向量求导, 得到一个 jacobin 矩阵 $J = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} & \frac{\partial y_1}{\partial x_3} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} & \frac{\partial y_2}{\partial x_3} \\ \frac{\partial y_3}{\partial x_1} & \frac{\partial y_3}{\partial x_2} & \frac{\partial y_3}{\partial x_3} \end{pmatrix}$

其中 $y_1 = f_1(x_1, x_2, x_3) = x_1^2$, y_2, y_3 同理!

Y 对每一个分量 x_i 的导数是: 各个分量函数 y_i 对 x_i 的偏导数沿某一方向 \vec{v} 的累积! 一般默认方向是 $\vec{v} = (1, 1, 1)$ 。比如 $\frac{d(Y)}{d(x_1)} = \frac{\partial y_1}{\partial x_1} + \frac{\partial y_2}{\partial x_1} + \frac{\partial y_3}{\partial x_1}$, $d(Y)$ 对 x_2, x_3 的导数以此类推。

所以 $\frac{d(Y)}{d(x_1)}$ 可以理解为关于 x_i 的偏导向量 $(\frac{\partial y_1}{\partial x_1}, \frac{\partial y_2}{\partial x_1}, \frac{\partial y_3}{\partial x_1})$ 在 \vec{v} 方向上的投影!

以链式法则 chain rule 来看, 也是这样, 如对 x_1 求导, 因为每个分量函数 y_i 里都带有 x_1 , 所以就是上述的结果!

高数中: $u = 3x + 2y, v = 2x + 3y, z = u + v \Rightarrow X = [x, y], Y = [u, v], z = g(Y)$, 所以以矩阵的角度来看, $\vec{y} = f(\vec{x}), l = g(\vec{y})$, 对每个变量 x_i 的求导方式用矩阵来计算:

$$J = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_n} \end{pmatrix} \rightarrow J^T = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_1}{\partial x_n} & \cdots & \frac{\partial y_m}{\partial x_n} \end{pmatrix}$$

利用链式求导里的中间导数 $v = \left(\frac{\partial l}{\partial y_1} \cdots \frac{\partial l}{\partial y_m} \right)^T$, 有:

$$J^T \cdot v = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_1}{\partial x_n} & \cdots & \frac{\partial y_m}{\partial x_n} \end{pmatrix} \begin{pmatrix} \frac{\partial l}{\partial y_1} \\ \vdots \\ \frac{\partial l}{\partial y_m} \end{pmatrix} = \begin{pmatrix} \frac{\partial l}{\partial x_1} \\ \vdots \\ \frac{\partial l}{\partial x_n} \end{pmatrix}, \text{ 其中:}$$

$$\frac{\partial l}{\partial x_1} = \frac{\partial l}{\partial y_1} \frac{\partial y_1}{\partial x_1} + \cdots + \frac{\partial l}{\partial y_m} \frac{\partial y_m}{\partial x_1}$$

$$\frac{\partial l}{\partial x_2} = \frac{\partial l}{\partial y_1} \frac{\partial y_1}{\partial x_2} + \cdots + \frac{\partial l}{\partial y_m} \frac{\partial y_m}{\partial x_2}, \dots \text{以此类推。}$$

所以, 利用 Jacobin 矩阵来一次性计算 l 对所有 x_i 的偏导累积:

- 若 l 是标量, 则 \vec{v} 可以按 $l = g(\vec{y})$ 计算出来
- 若 l 是向量, 则 \vec{v} 一般默认取 $(1, 1, 1)$ 的方向, 也可以按需求取其他任意方向!

注意: 如果只有 $\vec{y} = f(\vec{x})$ (也就是上述第二种情况), 想得到 $\frac{d(y)}{dx}$, 会在计

算图中添加一个运算 $l = g(\vec{y})$, l 是标量! (实际上 $l = \text{sum}(\vec{y})$, 因为 \vec{v} 默认 = 全 1) 当进行 $l.backward()$ 实际上是 $y.backward(\vec{v})$, 这个 \vec{v} 一般取与 \vec{y} 维度相同的全 1 矩阵, 这样得到的就是 $[\frac{d\vec{y}}{dx_1}, \frac{d\vec{y}}{dx_2}, \dots]$, 因为 \vec{v} 把 $\frac{dl}{dy_i}$ 全部变成了 1。此处 \vec{v} 可以理解为对应 \vec{y} 的 $\frac{dl}{d\vec{y}}$ 。